UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO – UFERSA

CAMPUS MULTIDISCIPLINAR PAU DOS FERROS

DISCIPLINA: TÓPICOS ESPECIAS EM SISTEMAS COMPUTACIONAIS II

PROFESSOR: THIAGO VALERIO DE SOUZA

DISCENTES: MARIA ALICE FERREIRA TEIXEIRA, THIAGO LUAN MOREIRA SOUSA

PAU DOS FERROS - RN

2026

Questão 1.

Foi calculada a correlação entre as variáveis AT, V, AP e RH com a produção de energia (PE). Observou-se que AT e V apresentam maior influência, com correlação negativa mais forte com PE. Já AP e RH possuem influência menor.

[15]
0s

```
correlacoes = dados[["AT", "V", "AP", "RH", "PE"]].corr()["PE"]
correlacoes
```

	PE
AT	-0.948128
V	-0.869780
AP	0.518429
RH	0.389794
PE	1.000000

dtype: float64

Questão 2.

A correlação entre as variáveis independentes mostrou que não há relações extremamente fortes entre elas, indicando que não há evidência clara de multicolinearidade significativa no modelo.

[16]
0s

```
dados.corr()
```

	AT	V	AP	RH	PE
AT	1.000000	0.844107	-0.507549	-0.542535	-0.948128
V	0.844107	1.000000	-0.413502	-0.312187	-0.869780
AP	-0.507549	-0.413502	1.000000	0.099574	0.518429
RH	-0.542535	-0.312187	0.099574	1.000000	0.389794
PE	-0.948128	-0.869780	0.518429	0.389794	1.000000

Questão 3.

Foi construído um modelo de Regressão Linear utilizando AT, V, AP e RH para prever PE. Os dados foram divididos em 80% para treino e 20% para teste. Por fim, o modelo é criado e treinado.

```
X = dados.drop(columns=["PE"])
y = dados["PE"]

X_treino, X_teste, y_treino, y_teste = train_test_split(
    X, y, test_size=0.2, random_state=42
)

modelo = LinearRegression()

# treinar o modelo
modelo.fit(X_treino, y_treino)
```

Questão 4.

O desempenho do modelo foi avaliado utilizando as métricas $R^2 = 0{,}93$, RMSE ≈ 4,5 e MAE ≈ 3,6. O valor elevado de R^2 indica que o modelo explica grande parte da variação da produção de energia, enquanto os valores relativamente baixos de RMSE e MAE mostram que o erro médio das previsões é pequeno. Dessa forma, o modelo pode ser considerado adequado para prever a produção de energia.

```
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
import numpy as np

# fazer previsões com o modelo treinado
y_pred = modelo.predict(X_teste)

# calcular métricas
r2 = r2_score(y_teste, y_pred)
rmse = np.sqrt(mean_squared_error(y_teste, y_pred))
mae = mean_absolute_error(y_teste, y_pred)

print("R²:", r2)
print("RMSE:", rmse)
print("MAE:", mae)
```

```
R²: 0.9301046431962188
RMSE: 4.502633229532186
MAE: 3.595913178273408
```

Gráfico

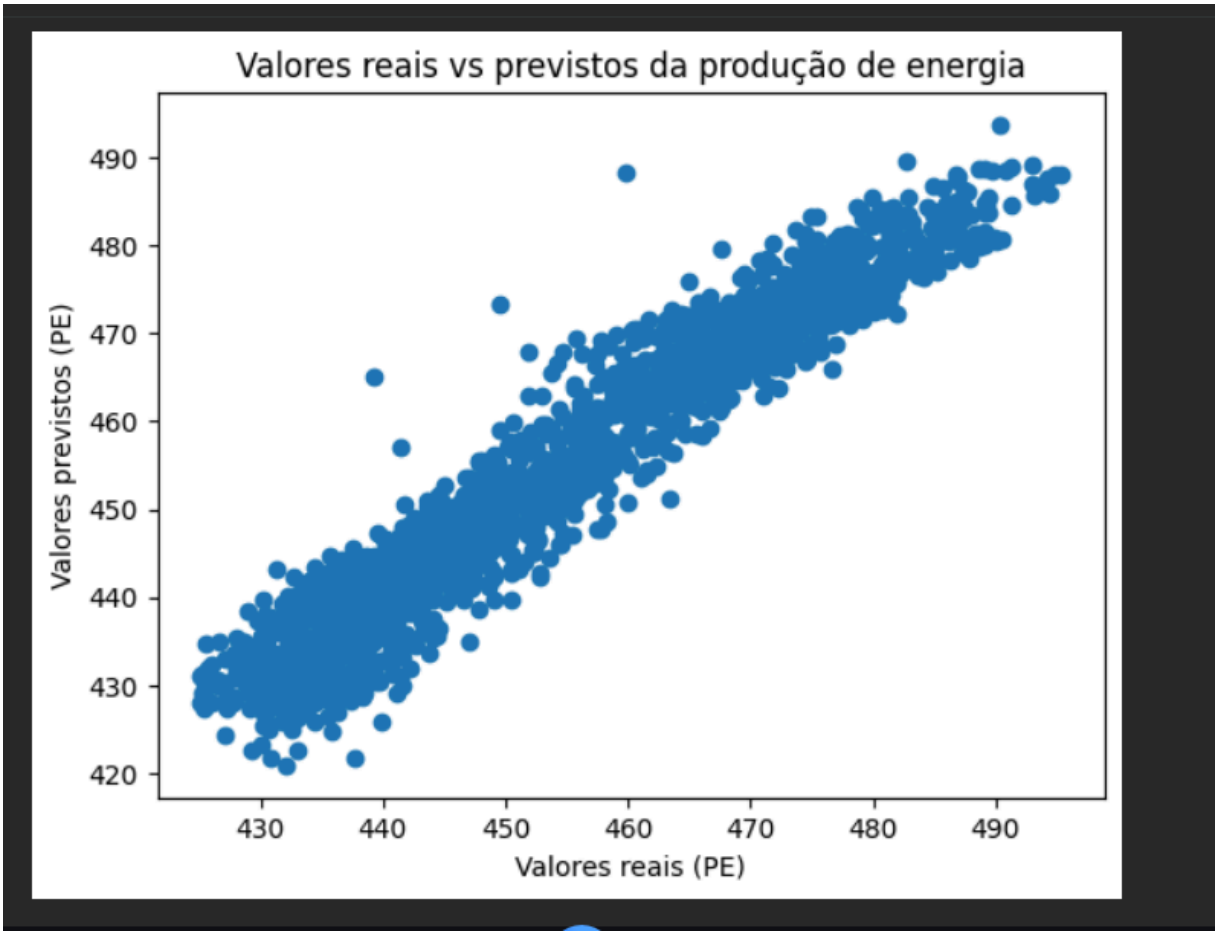
Valores reais vs previstos da produção de energia
Valores previstos (PE)
490
480
470
460
450
440
430
420
430
440
450
460
470
480
490
Valores reais (PE)